

# Seletor Fuzzy de Slice para Rede 5G

Marco Antonio Firmino de Sousa

20 de setembro de 2022

## Resumo

Uma das principais contribuições levantadas pelas redes 5G refere-se a possibilidade da criação de *slices*, que constituem uma fatia virtual da rede que visa atender serviços específicos e oferecer isolamento entre as aplicações entregando garantia de SLA *on-demand*. Tal contribuição se constrói sobre problemas de características estocástica e multivariável. A aplicação do conceito de *Network Slicing* é apontado como o caminho para novas soluções de redes móveis, incluindo as redes 5G e adiante. O problema de seleção de *slices* para redes 5G constituiu um problema ainda aberto, não dispondo de uma técnica totalmente aceita. No presente trabalho, busca-se a priori, a utilização de técnicas de Inteligência Artificial, como K-Means, para a realização de agrupamento de dados provenientes do fluxo do tráfego de rede para identificar o perfil dos dados do usuário considerando o fator de *slices* pré-existente. Dado o agrupamento, é realizado a análise para reconhecer a assinatura única de cada grupo com a finalidade de criar regras fuzzy para reconhecer os grupos. Para efeito de experimento, o processamento realizado mostrou-se viável, no sentido de realizar a seleção de *slice* pré-existente considerando dados proveniente da própria rede, sendo este não intrusivo quanto a sensibilidade dos dados da rede. Também mostrou-se versátil, pois o procedimento permite substituir ou aprimorar o conjunto de regras do motor de inferência, como também incorporar novas variáveis linguísticas. Assim, a arquitetura *Network Slicing*, com um serviço bem definido e robusto de *Slice Selection*, surge como a uma função de rede ou módulo a ser incorporado à Arquitetura da Rede 5G, possibilitando a integração e adequação em diversos segmentos e nichos de aplicações. Esta questão por si só é de extrema relevância, visto que não existe ainda padrão de indústria definido e comercializável.

## 1 Introdução

A rede 5G possui características disruptivas desde sua concepção [18, 11] e o aumento absurdo de sua velocidade passa a ser apenas uma de suas qualidades. Planejada para alcançar taxas de pico da ordem de 20 Gbps e prover a experiência de 100 Mbps para um número alto de usuários simultâneos [16], a tecnologia 5G é voltada para atender demandas existentes em cenários como da Internet das Coisas (IoT), com grande quantidade de dispositivos conectados; das redes veiculares (V2X), com dispositivos em movimento podendo comunicar-se com outros veículos, pessoas, infra e rede necessitando de ultra-confiabilidade; aplicações de realidade virtual (VR) e aumentada (VA) com a ultra-baixa latência como exigência e taxas de transferências extremas requeridas pela transmissão de vídeos em UHD. A implementação de solução única através de hardware para atender essas demandas não entregaria a flexibilidade exigida pelo problema a um custo viável e complexidade aceitável [22]. Desta forma, um norteador das soluções para a rede móvel de quinta geração é a substituição de hardware por software.

Desta maneira, com uma arquitetura flexível e o propósito de atender ao usuário, a utilização de sistemas computacionais estão presentes desde os *Radio Access Network* - RAN, até o Núcleo da Rede (*Core Network*). A elasticidade oferecida pelos softwares permite que composições dos recursos ocorram dinamicamente entregando soluções personalizadas aos demandantes da rede [20]. As tecnologias que permitem esta composição são, principalmente, a *Network Function Virtualization* - NFV que possibilita aos operadores da rede desacoplar funções e serviços da rede de hardware proprietário. Assim, recursos como *Serving Gateway*, *Domain Name Service*, *Cache*, *Firewall* podem compor a rede como serviços em nuvem, não mais em equipamentos dedicados. Para organizar as funções virtualizadas a *Software Defined Networks* - SDN possibilita a rápida implantação de serviços, a programabilidade da rede, além de introduzir a capacidade de processamento de borda na rede. Outra característica da rede 5G, possível em função de sua implementação por software, é o fatiamento da rede.

Em suma, uma das principais contribuições levantadas pelas redes 5G refere-se a possibilidade da criação de *slices*, que constituem uma fatia virtual da rede que visa atender serviços específicos e oferecer isolamento entre as aplicações entregando garantia de SLA *on-demand*. Tal contribuição se constrói sobre problemas de características estocástica e multivariável. A aplicação do conceito de *Network Slicing* é apontado como o caminho para novas soluções de redes móveis, incluindo as redes 5G e adiante. Entretanto, embora diversas propostas apontem caminhos promissores, ainda não é possível a agregação das diversas funcionalidades em uma abordagem única e totalmente funcional, que defina os mecanismos de operação e gerenciamento de cada *slice*, além de fornecer subsídios para escalabilidade, orquestração e apoio na decisão em domínios envolvendo tecnologias heterogêneas [10, 16].

Desta forma, o monitoramento de dados do tráfego de entrada da rede ou histórico de comportamento dos *slices* em forma de dados brutos por *streaming* permitem representar o comportamento real da rede em termos de QoS e servir de base para a obtenção de modelos ótimos [22]. Neste sentido, diversas técnicas computacionais podem ser

utilizadas, e.g., Algoritmos Evolucionários, Redes Neurais, Funções Utilidade, Lógica Fuzzy, Métodos de Tomada de Decisão Multiatributo, Processo de Decisão de Markov, Aprendizado de Máquina, dentre outras. A técnica considerada mais eficiente deverá, portanto, partir de modelos estatísticos ou modelos não-lineares.

A construção da base de conhecimento para o uso da Lógica Nebulosa permite que o especialista de domínio possa visualizar o comportamento do sistema de forma completa, mesmo em situações complexas e críticas. No trabalho de Ioannou [7], o uso de Lógica Nebulosa ocorre para o tratamento de valores do sistema de negociação e autorização de ingresso à rede que excedem os limites de valores esperados pelo sistema de controle. O contexto do projeto envolve um ambiente distribuído e a Lógica Nebulosa é parte de um sistema maior que faz uso de sistema de Crenças e Aprendizado de Máquina.

Como possibilidade de utilização da Lógica Nebulosa, o presente projeto visa ampliar a capacidade do sistema apresentado em Chagas [4], o qual realiza a seleção de slice a partir do fluxo da rede. Com o uso de técnicas de agrupamento e decisores matemáticos realiza a predição do slice apropriado ao requisitante. Assim, a Lógica Nebulosa agrega ao sistema a capacidade de tratar dados de entrada não esperados (outliers), como em Ioannou [7]. Desta forma, tem-se o ambiente com escopo bem definido para utilizar a Lógica Nebulosa, como também a base de dados para comparação.

Nesta proposta de trabalho, busca-se a priori, a utilização de técnicas de Inteligência Artificial para definição e implementação de modelos de alocação de recursos fim-a-fim, após o processo de análise dos *slices* disponíveis em uma determinada área de cobertura de serviços. A escolha inicial não exclui a necessidade da realização de estudos com outras heurísticas e meta-heurísticas de aprendizado supervisionado e não-supervisionado, além de soluções híbridas buscando um eficiente mecanismo de computação para seleção de *slices*, garantindo o cumprimento dos SLA's e a experiência do usuário final. De maneira geral, os esforços estão concentrado em garantir a estabilidade na entrega dos dados, bem como a manutenção dos serviços ativos pelo usuário final, mesmo em cenários que apresente pouco ou média mobilidade. Para tal, faz-se necessário o estudo do fluxo de dados do tráfego de rede, a análise de agrupamento para composição de classes e, por fim, a representação do problema através de um sistema de lógica nebulosa.

## 1.1 Arquitetura 5G

A quinta geração de rede móvel (5G) apresenta uma arquitetura primordialmente virtualizada, diferentemente das gerações anteriores de rede móvel, que eram baseadas em módulos físicos acoplados na infraestrutura. A virtualização incorpora à rede a flexibilidade necessária para atender a demanda crescente, dinâmica e conflitante no uso simultâneo dos recursos. A virtualização da rede 5G também permite que os recursos sejam alocados de forma mais eficiente, o que resulta em um melhor desempenho da rede. Desta forma, permite aos usuários acessar aplicativos e serviços em tempo real, como realidade aumentada e virtual, carros conectados e muito mais.

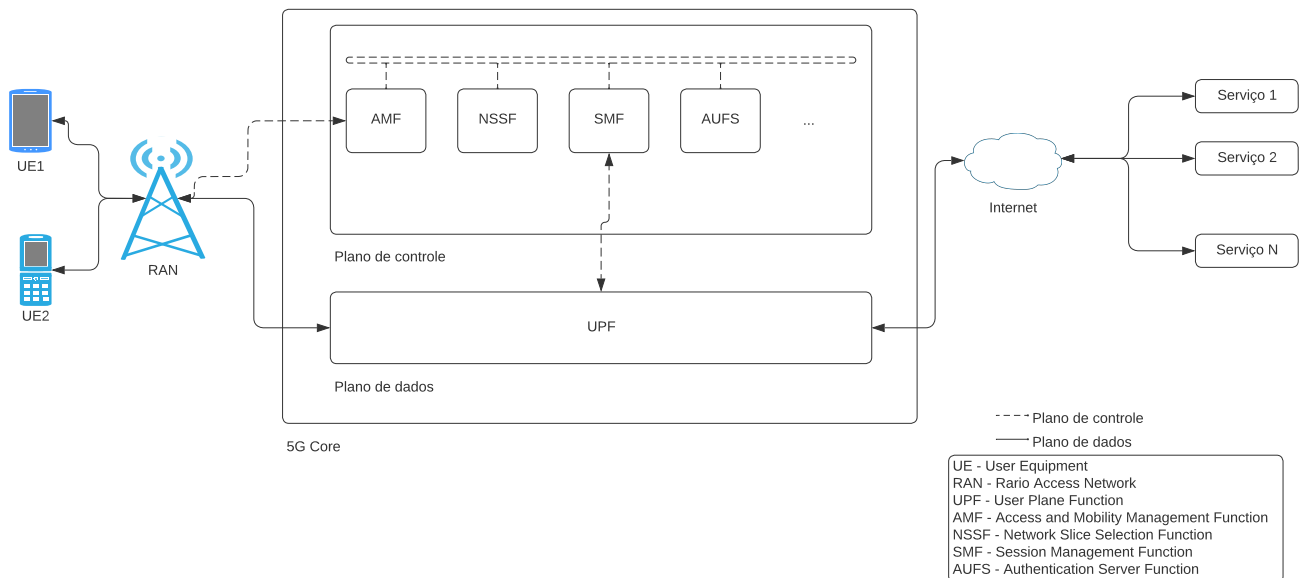


Figura 1: Visão simplificada da Arquitetura 5G baseada na especificação 3GPP [11] e em [8].

A Figura 1 exibe uma abstração da arquitetura da rede 5G. Nessa figura, é possível destacar a presença dos Equipamentos do Usuário (do inglês User Equipment), a infraestrutura da rede e o acesso aos serviços requisitados pelos usuários. O fluxo de dados é representado, de forma simplificada, com a requisição de acesso à rede pelo UE, onde através do Radio Access Network (RAN) ocorre a verificação de permissão na função de rede Access and Mobility Management Function (AMF). Uma vez autorizado o acesso, ocorre a construção de uma sessão de conexão do UE na função de rede Session Management Function (SMF). Por sua vez, a estrutura apta a fazer uso

de fatiamento de rede para garantir Acordos de Níveis de Serviços (SLA), requisita a função de rede Network Slice Selection Function (NSSF) para selecionar um slice adequado ou iniciar a construção de um slice exclusivo para atender à demanda do usuário. Desta forma, o usuário passa a trafegar por toda a estrutura da rede 5G com um canal exclusivo, com garantias de qualidade de serviços e experiência (QoS e QoE).

Além disso, outra característica importante presente na Figura 1, é a separação dos planos de controle e de dados, onde todas as funções administrativas possuem uma rede própria e separada de todo o tráfego produzido pelos usuários. Assim, todos os equipamentos do plano de dados (servidores, roteadores, switches, etc) não possuem funções administrativas ativas, ou seja, não é possível acessar estes equipamentos através da rede de dados pelos usuários, somente através da rede administrativa. Desta forma, o operador do sistema pode incorporar novas funções, atualizá-las com facilidade, pois são funções ou módulos virtualizados. E desta forma, ocorre a instância de fatiamentos de redes, a orquestração de recursos para a melhor experiência de usuário.

## 1.2 Network Slicing

O *Network Slicing* é uma técnica que permite a multialocação de recursos para instanciar uma rede virtual fim-a-fim garantindo o isolamento, separação lógica e física de recursos. Em função do isolamento é possível instanciar, em uma infraestrutura comum, *slices* com propósitos conflitantes entre si. Assim, otimizando a infraestrutura para garantir o atendimento de demandas diversas dos usuários.

A personalização da entrega de uma rede em função de diferentes cenários de mercado e negócios ocorre por capacidade de particionamento lógico da rede 5G. O *Network Slice* (NS) é um atributo fundamental da rede 5G, mas que carrega em si uma complexidade para sua eficiente implementação. A possibilidade de alocar recursos e fatiar a rede em provisionamento dinâmico por software em um ambiente descentralizado, virtualizado alça questões de qualidade e gerenciamento de recursos para garantir o funcionamento do serviço [8, 19].

Dentre os benefícios em utilizar o conceito de fatiamento virtual na rede 5G, reformulado em [11], sob uma infraestrutura física comum, três pontos são destacados por [10]: (i) implantação dinâmica de uma estrutura de rede com emprego de capital reduzido (CAPEX) e curto espaço de tempo; (ii) habilidade de entregar uma rede estreitamente acoplada aos seus serviços; (iii) capacidade de delegar o gerenciamento do fatiamento de rede ao locatário/utilizador do serviço. O item (i) possui forte vinculação às necessidades existentes da indústria vertical na utilização rede 5G e como principal desafio destaca-se a capacidade de reservar dinamicamente recursos da rede [19, 22].

Tanto a SDN, quanto a NFV requerem recursos de vários domínios técnicos, como rede de acesso de rádio, rede de transporte, nuvem e computação de borda. Este contexto diverso e fortemente distribuído permite arranjos de recursos para atender as particularidades exigidas pelos serviços. Por exemplo, em [6, 12, 19, 23], exploram o transporte de parte da computação em nuvem para a computação na borda, ampliando a capacidade de resposta da rede em função da proximidade com os usuários finais, tal abordagem é conhecida por Computação em Neblina, ou Fog Computing [9], e um possível *slice* local atenderia à demanda do usuário.

Ao considerar o *network slicing*, um conceito chave para prover uma plataforma de rede ágil, a utilização de múltiplas instâncias de rede compartilhando recursos físicos exigem a capacidade do sistema gerir e orquestrar recursos. Além da flutuação de recursos, condições de rádio e rede, o sistema deve suportar o gerenciamento do ciclo de vida das aplicações, instanciar e encerrar uma aplicação, sob demanda ou por solicitação de um terceiro autorizado. Taleb [20] enumera alguns dos principais serviços para operação eficiente no processo de orquestração:

- alocação de recursos: ponto chave para o sistema que deve considerar a disponibilidade de CPU, memória, armazenamento, largura de banda da rede e contenção de recursos;
- localização do serviço: a escolha adequada de onde implantar os MEC a fim de garantir que os usuários recebam o desempenho desejado em termos de velocidade e capacidade dos serviços;
- seleção de borda: estabelecer critérios para a escolha da borda utilizada pelo usuário, pois nem sempre a mais próxima é a melhor opção quando se trata de incerteza de movimentação e condições de rede;
- confiabilidade: estabelecer critérios de tolerância a falhas sem prejudicar a capacidade de escalonamento do sistema.

A quantidade de parâmetros, contextos e heterogeneidade da rede em função da incorporação de serviços torna a orquestração do sistema um desafio de pesquisa [20]. Tamaña diversidade permite a exploração e implementação de diversos cenários e abordagens de pesquisa atacando gargalos existentes que exigem soluções com a utilização de ML, como a aplicação de algoritmos online ou totalmente distribuídos e aprendizado colaborativo [17].

A personalização completa da utilização de slices em uma rede 5G ocorre sob demanda, com a exigência de controle, orquestração de recursos, gerenciamento do ciclo de vida dos serviços e recursos alocados. Uma segunda maneira de utilizar o fatiamento da rede 5G é com a disponibilização de *slices* pré-existentes e entregar ao usuário o acesso ao *slice* que atende ao tipo de demanda exigido. Por exemplo, um *slice* voltado para atender à demandas veiculares, como baixo *delay* e alta confiabilidade, deve ser atribuído aos usuários com este tipo de exigência. Desta forma, o problema de *slice*, momentaneamente, é simplificado e passa ao contexto único de seleção de *slice*.

## 2 Inteligência Artificial nas Redes 5G

O Aprendizado de Máquina (AM) é uma subárea da Inteligência Artificial que busca desenvolver métodos computacionais para a obtenção de sistemas capazes de adquirir conhecimento de forma automática. Por sua vez, o conhecimento se refere ao armazenamento de informações ou criação de modelos que possam ser utilizados por pessoas ou máquinas para prever e responder apropriadamente ao mundo exterior [5]. O principal desafio do AM é maximizar a capacidade de generalização do aprendizado para dar respostas satisfatórias em função dos dados ou amostras de dados utilizados.

No vasto universo de possibilidades de aplicações da Inteligência Artificial (IA) no contexto das redes 5G, algumas são destacadas no trabalho [1], que buscou através de entrevistas a responsáveis de empresas da indústria de telecomunicação, mapear as principais frente de atuação em curso e projetos futuros com soluções norteadas por IA. Destacam-se a manutenção preditiva, detecção de falhas, previsão de demanda de tráfego, otimização de operações de rede, medição inteligente, *smart grid*, design de arquitetura de rede, implantação de rede. Estas frentes enquadram-se em todas as fases do ciclo de implantação e operacionalização da rede 5G. Quanto às técnicas de IA são utilizadas desde Sistemas Especialistas - *Expert Systems* (ES) a Aprendizado de Máquina - *Machine Learning* (ML) e, em alguns casos, ocorre a utilização de Aprendizado Profundo - *Deep Learning* (DL). Em função do contexto das redes 5G com a adoção de sistemas modernos, flexíveis e programáveis (SDN e NFV), as aplicação de ML e DL em substituição aos ES são possíveis e desejáveis. Esta substituição natural é respaldada pelo volume de dados disponível na rede, sua concepção de ser totalmente autônoma [22] e pelo interesse em sistemas com a capacidade de aprenderem por si que permitem a automatização de processos complexos.

Um modelos de ML para o contexto de arquitetura orientada a serviços com entrega de Redes como Serviço (*networks-as-a-service*), dotado da função de gerir as estruturas físicas e virtuais respeitando Acordo de Nível de Serviço (*Service Level Agreement* - SLA), visando o objetivo de entregar performance exigida em diferentes definições de serviços é apresentado em [22]. O trabalho discute uma metodologia para criação de ML estabelecendo um fluxo de dados, gerenciamento de *slice* e um esquema pró-ativo de controle dos modelos em utilização. O modelo pró-ativo proposto mantém a responsabilidade de ações para avaliar, substituir, implantar os modelos em uma tentativa de estabelecer um ciclo de vida em tempo de execução. Desta forma, fica evidente a necessidade de constante avaliação de modelos criados, como também a pluralidade de modelos para cada contexto.

De forma semelhante [13] propõem a criação de um modelo de ML para melhorar a eficiência de um sistema para a Rede 5G, todavia aplicado em um *Multi-access Edge Computing* - MEC, desta forma exigindo a aplicação de IA em um contexto distribuído. Dois algoritmos são apresentados e avaliados considerando escalonamento de tarefas e teoria dos jogos para o modelo de aprendizado de máquina e alcançando estabilidade em contexto de grade escala.

Em uma abstração centralizada sob um ambiente distribuído [14] *apud* [3], propõem um modelo de arquitetura intitulado por *Knowledge-Defined Networking* (KDN). Sua proposta é estabelecer limites para a sondagem da rede ao coletar dados para a avaliação do sistema, estabelecer blocos funcionais para a implementação de um modelo de controle, coleta de dados, bloco de conhecimento. O SDN realiza a coleta de dados e os fornece para um bloco de conhecimento voltado para algoritmos de Q-Learning e coordenados por um bloco de gerenciamento.

Com uma abordagem diferente, [21] busca avaliar a robustez de modelos de ML em cenários de ataques a rede 5G. Apesar da conclusão de fragilidade em diversos cenários, o trabalho realiza a contribuição positiva de agrupar técnicas e algoritmos de ML utilizados em fases distintas da arquitetura da rede 5G, os organizando em Aprendizado Supervisionado, Não-supervisionado e por Reforço. Desta forma, a ótica de robustez, segurança e performance são objetivos no desenvolvimento de modelos de ML para redes 5G.

Os trabalhos citados acolhem um ponto comum: as redes 5G possuem uma capacidade de gerar e manipular um grande volume de dados, o que acarreta na necessidade de associar aos modelos de ML técnicas de engenharia de dados voltados para *Big Data*.

## 3 Análise do agrupamento

A utilização de metodologias estabelecidas no universo de aprendizado de máquina [?], pode vir a contribuir e instituir um método factível e replicável para o desenvolvimento de modelos para diferentes cenários de redes de computadores. O método, resumidamente, é estruturado em três fases:

- Pré-processamento: seleção de dados, limpeza, normalização;
- Mineração de Dados: processamento por algoritmo estatístico ou IA;
- Pós-processamento: realização de análise e validação de padrões.

Desta forma, a Descoberta de Conhecimento em Base de Dados permite a reflexão sobre a utilização de diversos modelos de algoritmo na fase de mineração. Esta abordagem pode gerar a padronização de dados de entrada provenientes de tráfegos de redes reais ou de simulações. Independentemente do modelo a ser utilizado, a coleta e geração de dados deve prover uma assinatura mínima deste dados, para garantir a diversidade na aplicação de algoritmos na fase dois do processo de análise.

Tabela 1: Especificação de largura de banda para cada User Equipment nos testes realizados.

Teste	UE 01 (Mbps)	UE 02 (Mbps)	UE 03 (Mbps)	UE 04 (Mbps)	UE 05 (Mbps)
01	20	47	07	09	06
02	22	45	06	12	08
03	24	49	09	10	06
04	32	55	14	18	12
05	25	50	10	05	02
06	45	70	30	05	03
07	12	25	05	20	30
08	20	22	24	02	07
09	08	28	05	10	03
10	32	62	22	15	08
11	10	15	05	02	15

Considerando o contexto de implementar um submódulo da função de rede NSSF (ver Figura 1), com o propósito de realizar a seleção de slice pré-existente, com a pretensão de avaliar a metodologia no contexto de tráfego de redes para a análise associada a utilização de *slice*, optou-se por definir um cenário controlado e gerar os dados com o atendimento a uma assinatura mínima e com baixo custo de aquisição.

### 3.1 Cenário dos Experimentos

Dada a necessidade de um dataset de tráfego de redes para a exploração, validação e desenvolvimento de modelos de ML, este trabalho optou por seguir o comportamento padrão apresentado em diversos artigos, o de construindo um cenário próprio e produzindo um dataset proveniente de uma simulação. Vale ressaltar ser compreensível este comportamento devido as característica amplas e diversas de cenários e necessidades das redes de computadores.

O ambiente de testes foi implementado utilizando o emulador de software de rede GNS3 (Graphical Network Simulator 3), com o objetivo de disponibilizar a infraestrutura para as funções virtualizadas de rede (NFV Infrastructure). O cenário é composto de 05 clientes (UE) transmitindo em diferentes taxas de tráfego, conforme especificado na Tabela 1, para o conjunto de testes realizados. Além disso, tem-se a implementação na estação rádio base 5G (gNodeB) através de um módulo de software (CU/DU) executando em uma VM Ubuntu Linux 16.04 LTS. No que tange, a borda da rede (Edge Computing) utilizou-se um container docker com o deploy do controlador SDN OpenDayLight, para implementar a função da UPF (User Plane Function), responsável pela separação e identificação dos fluxos de dados. Além disso, fez-se a implementação da função de rede NWDAF (Network Data Analytics Function) em uma VM Ubuntu Linux 16.04 LTS com o framework python Anaconda 3, com o objetivo de implementar as funções de análise e o pipeline de mineração de dados, fazendo uso da ferramenta jupyter notebook e das bibliotecas Numpy, Pandas e Sklearn.

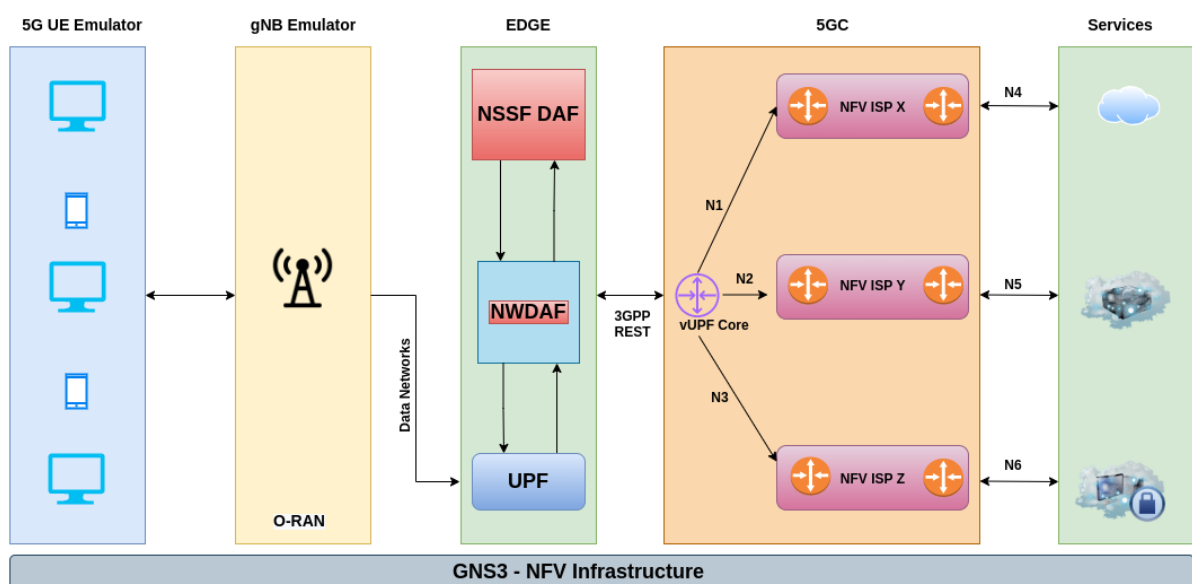


Figura 2: Ilustração da arquitetura do ambiente de simulação para produção do tráfego de rede.

É importante destacar que embora o cenário apresente o núcleo da arquitetura 5G (5G Core – 5GC), não implementou-se nenhuma das funções de rede (NFs) pertinentes ao core, tais como: AUSF, NEF, NRF, PCF, NSSF

e UDM, conforme apresentado na Figura 2. Essas funções de rede serão implementadas através do Open Source Mano (OSM) da ETSI NFV, que fará uso do template SLA gerado pela função NWDAF. Contudo, considerou-se 03 slices verticais, detalhados a seguir, entregues na borda da rede pelo operador 5G. Em relação a representação dos serviços (services) utilizou-se um servidor Iperf, para diferentes taxas de transmissão de tráfego do tipo CBR (Constant Bit Rate).

- Slice 01: Remote Driving
  - E2E Latency (5ms) → máxima
  - Reability (99.999%) → mínima
  - Data rate
    - \* (UL: 25Mbps) → mínima
    - \* (DL: 1 Mbps) → mínima
- Slice 02: Rural Macro
  - E2E Latency (Não especifica)
  - Reability (Superior a 80%)
  - Data rate
    - \* (UL: 50Mbps)
    - \* (DL: 25Mbps)
- Slice 03: Wireless Road-Side Infrastructure Backhaul (ITS)
  - E2E Latency (30ms) → máxima
  - Reability (99.999%)
  - Data rate: 10Mbps

Como resultado para cada um dos onze experimentos da simulação, obteve-se um arquivo para cada cliente contendo 33 dados de conexões com intervalo, transferência, banda e protocolo. Para os dados de avaliação de cada slice, para cada experimento foi gerado um arquivo contendo latência, jitter, perda de todas as conexões realizadas. Desta forma, estes dados brutos de log são o ponto de partida para a realização do processo de análise de dados.

### 3.2 Descoberta de Conhecimento

No processo tradicional de análise de dados enamorar-se pelo conjunto de dados faz parte da primeira etapa. Neste sentido, para conhecer e preparar os dados para o processo de análise de agrupamento, seguiu-se com as tarefas do pré-processamento de dados:

- Coleta de dados da simulação;
- Seleção de dados;
- Purificação de dados;
- Construção de dataset;

Para efeito de experimento são considerados seis 6 atributos a serem organizados no dataset, contudo o operador da rede pode adicionar métricas para atender cenários diversos desde que possa coletar os dados da rede. Para validar este princípio, foram adicionados outros dois critérios ao dataset: confiabilidade e distância. Estes, por sua vez, foram gerados aleatoriamente respeitando um intervalo pré-defino dentro do normalmente existente em cenários reais. Assim, o dataset padrão passou a possuir os seguintes atributos:

- Latency
- Jitter
- Loss
- Protocol
- Bandwidth
- Transfer
- UE: User Equipament, não utilizado no processo de construção do modelo.



- Experiment: id do experimento, não utilizado no processo de mineração.
- Distance

No pré-processamento os dados são analisados quanto ao tipo, intervalo e, nesta fase é comum a ocorrência de ações de tratamento e normalização aplicados aos registros. Desta maneira, os dados possam vir a servir e adequar-se ao padrão de entrada do algoritmo de mineração de dados utilizado na etapa futura. No sentido de reconhecer os dados, para efeito de ilustração, a Figura 3 apresenta o gráfico de distribuição de densidade das métricas coletadas do fluxo de tráfego de rede.




Figura 3: Ilustração da arquitetura do ambiente de simulação para produção do tráfego de rede.

No processo de mineração houve uso do algoritmo de classificação ou agrupamento K-Means que utiliza dados numéricos. Para o processo de aprendizagem passou a considerar somente os atributos relevantes para o experimento:

['Latency', 'Jitter', 'Loss', 'Protocol', 'Bandwidth', 'Transfer', 'Distance', 'Reliability']

O agrupamento realiza a análise de dados em busca de reconhecer o comportamento de grupo dos dados de maneira que um elemento seja caracterizado em um grupo e claramente seja diferente dos outros grupos. O k do K-Means indica quantos são os grupos separáveis do conjunto de dado. Uma técnica para encontrar o valor adequado de k para um dado conjunto é aplicar o Método de Elbow Plot pelo cálculo da soma do erro médio quadrático (SSE). O ponto de Elbow ocorre no momento que o SSE começa a diminuir de forma linear. Desta maneira, no dataset utilizado, o k apropriado é 3, conforme pode ser observado na Figura 4 que apresenta o SSE para k de 1 a 8.

Por fim, ao assumindo o k igual a 3 ocorre o processo de aprendizado e treinamento com a separação dos elementos em três grupos que caracterizam cada slice. A etapa seguinte à mineração de dados é a análise onde busca-se entender o resultado encontrado. Para esclarecer esta etapa a ilustração das Figuras 5, 6 e 7 apresentam as características únicas de cada agrupamento que, de certa forma, refletem as características de cada slice utilizado no sistema de simulação GNS3. Uma vez o modelo treinado, o sistema passa a ser capaz de receber qualquer fluxo de dados dentro do intervalo médio do treinamento, para forçar a predição do slice adequado para a alocação.

Na etapa de análise do resultado produzido pelo processo de mineração é explorada a capacidade de gerar ilustrações, sempre no sentido de validar o conhecimento adquirido. Tal conhecimento deve ser útil, novo e aplicável ao contexto do problema.

Todavia, o resultado encontrado no processo de análise de agrupamento com utilização do algoritmo K-Means é uma etapa intermediária para o presente projeto. O resultado apresentado nas Figuras 5, 6 e 7, a inclusão do campo de saída no dataset que indica o slice adequado ao UE (Tabela 2), bem como a caracterização de cada slice apresentada em [Cenário dos Experimentos](#) são os recursos utilizados para a construção do Sistema Fuzzy de Seleção de Slice.




Figura 4: Descida do Erro Médio Quadrático para  $K = 1$  até  $K = 8$ .




Figura 5: Caracterização única do agrupamento 'Cluster 1'.




Figura 6: Caracterização única do agrupamento 'Cluster 2'.

### 3.3 Aplicação da Lógica Nebulosa

Diversas soluções têm sido propostas no sentido de avaliar e selecionar a melhor rede disponível, considerando um conjunto de critérios, mesmo antes do surgimento da especificação das redes 5G. Algumas dessas soluções são computacionalmente viáveis, outras impõem modelos restritivos que requerem um esforço computacional maior, o



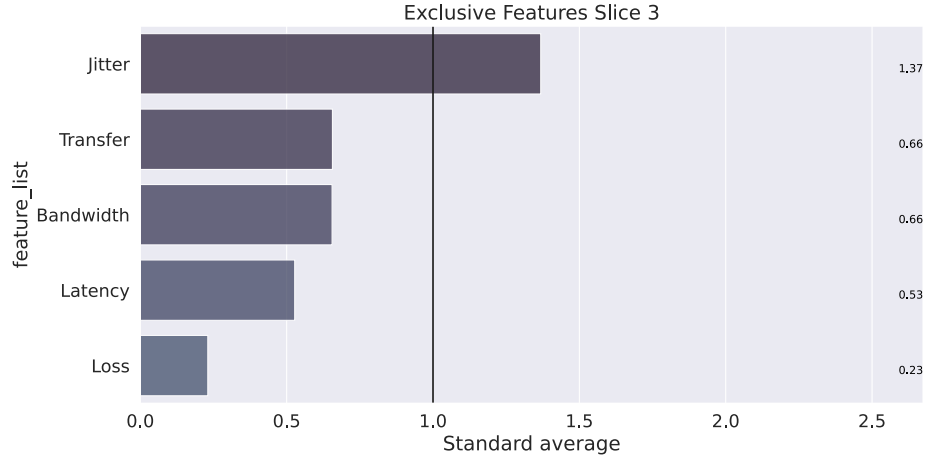


Figura 7: Caracterização única do agrupamento 'Cluster 3'.

Tabela 2: Amostra do dataset normalizado com a inclusão da classe de saída 'Cluster'.

Latency	Jitter	Loss	Bandwidth	Transfer	Distance	Reliability	Cluster
0.675982	0.026256	0.451613	0.311063	0.314385	0.581830	0.758733	2
0.165408	0.202952	0.000000	0.356844	0.357136	0.456873	0.486860	0
0.697885	0.042833	0.290323	0.885661	0.885731	0.568301	0.606192	1
0.219033	0.202095	0.064516	0.714153	0.714327	0.431437	0.361822	1
0.697885	0.042833	0.290323	0.885661	0.885731	0.948789	0.930132	1

que pode acabar por inviabilizar a solução [2, 15].

Com a clareza estabelecida no contexto do presente projeto: as classes (Tabela 2); os tipos de slices (Lista característica dos slices no [Cenário dos Experimentos](#)); os intervalos para cada atributo (Tabela 3); e as assinaturas no dataset para cada slice bem especificados (Figuras 5, 6 e 7). Inicia-se a construção do Sistema Fuzzy para Seleção de Slice com as variáveis linguísticas para o sistemas.

Desta forma, para cada atributo a ser considerado no sistema, uma representação para o sistema fuzzy é construído considerando valores linguísticos facilmente explicáveis e compreensíveis para um especialista de domínio da aplicação. Isto torna a modelagem do problema mais intuitiva e de fácil interpretação, como pode ser observado no conjunto de ilustrações da Figura 8.

Um fator importante para a utilização da lógica fuzzy em relação ao contexto de agrupamento com uso do algoritmo K-Means é a eliminação do processo de normalização dos dados para processamento, bem como a necessidade de utilizar exclusivamente dados numéricos não categóricos. O sistema fuzzy é mais suscetível ao ruído ao considerar os limites dos intervalos superior e inferior para cada atributo de entrada abertos. A Tabela 3 apresenta os intervalos encontrados no dataset, que são considerados como um fator de direcionamento para a construção das variáveis linguísticas, mas sua construção (Figura 8) considerará os intervalos inferior e superior abertos. Desta forma, o sistema passa a aceitar e tratar valores não comuns ao sistema, os *outliers*.

Os intervalos para cada atributos são extraídos do dataset original:

Tabela 3: Intervalos inferior, superior e valor médio para cada atributo do dataset original (não normalizado)

Atributo	Limite inferior	Limite superior	Valor médio
Latency	0.554000	1.87800	1.067772
Jitter	0.104945	2.14846	0.414752
Loss	0.000000	3.10000	4.115286
Bandwidth	32.507692	7.00000	18443.505199
Transfer	139.000000	2.50300	658836.094184
Distance	6.025444	9.79297	53.449390
Reliability	99.984021	9.99989	99.992160

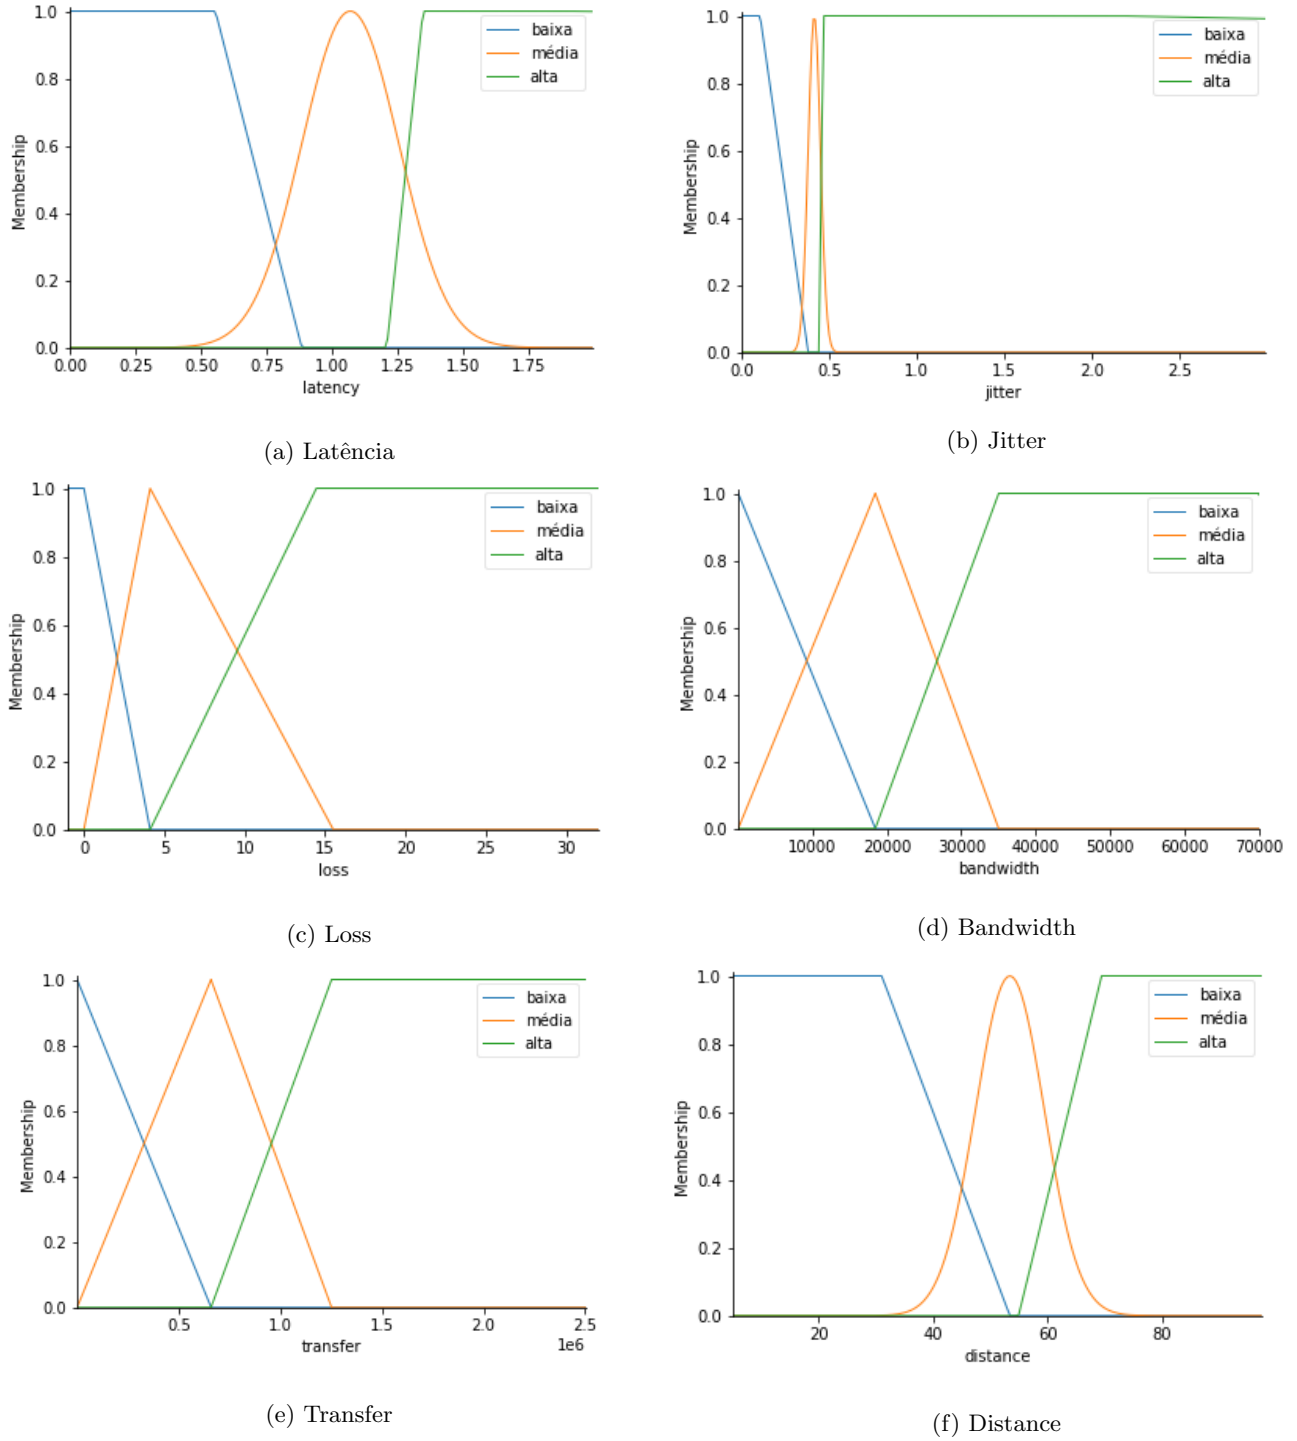


Figura 8: Variáveis linguísticas de entrada do sistema fuzzy. Mapeiam os atributos coletados no tráfego da rede.

A saída do sistema é a indicação do mais apropriado 'Slice' para o usuário, tendo como a variável de saída a variável "slice". A representação da saída é apresentada na Figura 9, onde é possível notar que sempre será recomendado ao sistema um 'slice' ao usuário.

As regras são construídas a partir da análise do agrupamento dos dados de forma a mapear cada um dos slices existentes no sistema (Figuras 5, 6 e 7). Desta forma, são construídas quatro regras para mapear cada um dos três slices existentes no sistema, totalizando doze regras. Por exemplo, em *R4* os atributos loss e latency são encontrados em valor alto na Figura 5, portanto, é possível facilmente perceber que trata-se de uma situação apropriada para o 'slice 1', visto que esta situação não é presente para 'slice 2' e 'slice 3', como pode-se observar nas Figuras 6 e 7.

- Conjunto de regras para capturar o tráfego para o Slice 1

R1 **SE** loss é baixa **E** latency é alta **ENTÃO** saída é slice 1

R2 **SE** bandwidth é baixa **E** transfer é baixa **E** jitter é baixa **ENTÃO** saída é slice 1

R3 **SE** distance é média **E** jitter é baixa **ENTÃO** saída é slice 1

R4 **SE** loss é alta **E** latency é alta **ENTÃO** saída é slice 1




Figura 9: Saída

- Conjunto de regras para capturar o tráfego para o Slice 2
  - R5 **SE** bandwidth é alta **E** transfer é alta **ENTÃO** saída é slice 2
  - R6 **SE** jitter é baixa **E** transfer é alta **ENTÃO** saída é slice 2
  - R7 **SE** jitter é baixa **E** bandwidth é alta **ENTÃO** saída é slice 2
  - R8 **SE** latency é média **E** jitter é baixa **ENTÃO** saída é slice 2
- Conjunto de regras para capturar o tráfego para o Slice 3
  - R9 **SE** loss é baixa **E** latency é baixa **ENTÃO** saída é slice 3
  - R10 **SE** bandwidth é baixa **E** loss é baixa **ENTÃO** saída é slice 3
  - R11 **SE** bandwidth é baixa **E** transfer é alta **ENTÃO** saída é slice 3
  - R12 **SE** jitter é média **E** loss é baixa **ENTÃO** saída é slice 3

A verificação de funcionamento do sistema fuzzy deu-se ao inserir como dado de entrada valores oriundos do dataset e aferir a saída do sistema como apropriada. A análise de processamento das entradas e cálculo de saídas válidas ocorreu com todo o dataset, sendo exibido uma amostra do procedimento nas Tabelas 4, 5 e 6 com suas respectivas saídas nas Figuras 10, 11 e 12.

Tabela 4: Dados de métricas da rede inseridos no sistema fuzzy para verificação de funcionamento: Registro 1.

Descrição	Valores
Latency	0.910000
Jitter	0.591290
Loss	1.000000
Bandwidth	20000.000000
Transfer	715000.000000
Distance	47.952992




Figura 10: Saída do sistema fuzzy após inserção dos dados do Registro 1 exibidos na Tabela 4

Tabela 5: Dados de métricas da rede inseridos no sistema fuzzy para verificação de funcionamento: Registro 500.

Descrição	Valores
Latency	0.846000
Jitter	0.475625
Loss	0.000000
Bandwidth	9008.000000
Transfer	322000.000000
Distance	22.840291




Figura 11: Saída do sistema fuzzy após inserção dos dados do Registro 125 exibidos na Tabela 5

Tabela 6: Dados de métricas da rede inseridos no sistema fuzzy para verificação de funcionamento: Registro 500.

Descrição	Valores
Latency	1.470000e+00
Jitter	2.463244e-01
Loss	5.000000e+00
Bandwidth	3.200000e+04
Transfer	1.144000e+06
Distance	6.646000e+01




Figura 12: Saída do sistema fuzzy após inserção dos dados do Registro 500 exibidos na Tabela 6

## 4 Análise de Resultados e Contribuições

Para efeito de experimento, o processamento realizado mostrou-se viável, no sentido de formalizar um dataset proveniente da própria rede, sendo este não intrusivo quanto a sensibilidade dos dados da rede. Também mostrou-se versátil, pois o procedimento permite substituir o algoritmo de K-Means, apropriado para agrupamento, por outros em busca de outras tarefas do processo de análise de dados. A possibilidade de utilizar um sistema compreensível por humanos, não caixa preta, permite a continuidade de manutenção e de mudança de escopo por outros membros da equipe.

Apesar de, por enquanto, a análise do fluxo desconsiderar a abordagem fim-a-fim, ocorre a otimização do tráfego da rede de acesso à borda. Desta forma, de posse do modelo de agrupamento de dados, o conjunto de regras e capacidade de separar o *slice* adequado ao usuário considerando seu contexto de fluxo, torna-se possível iniciar o processo de classificação para recomendar o *slice* ao usuário. Dada a assinatura do fluxo de dados exigido para o modelo e, por fim, sua capacidade de recomendar um *slice* considerando suas características, como trabalhos futuros busca-se utilizar outros modelos de aprendizagem de máquina na etapa de mineração de dados, além de explorar

algoritmos para transcrever as características do *slice* em formato exigido pelas ferramentas de orquestração, desta forma permitindo que o processo de redes automatizada alcance mais um degrau.

## 5 Conclusão

A definição de modelos de seleção de *slice* sob demanda apresenta características estocásticas, multivariável e dinâmicos variantes no tempo. Desta forma, a obtenção de um modelo ótimo para determinados cenários e contextos de utilização torna-se bastante complexo. Neste sentido, a utilização de Inteligência Computacional (IC) e *Machine Learning* na proposição de modelos, bem como formulação de problemas multiobjetivos é bastante salutar.

A principal contribuição deste trabalho consiste em propor um sistema fuzzy para seleção de *slices* compreensível e facilmente adaptável a novos contextos de redes móveis 5G, que compreenda incorporação de novas métricas de rede, com a utilização de inteligência computacional de forma transparente para a seleção de *slices on-demand*. Respeitando o fluxo ou *pipeline* tradicional na análise de dados por meio de um padrão flexível de entrada e a obtenção de um padrão de saída.

A utilização de dados de *streaming* da própria rede para prover o treinamento do modelo de agrupamento e a realização de predição permitem a sua reavaliação e atualização de forma transparente. Com a definição de métricas e parâmetros para a construção do modelo o armazenamento destes dados para compor um histórico contendo a composição dos *slices*, seu desempenho na borda e no *core* torna-se possível a análise por técnicas de *Big Data* em busca de melhoria do modelo ou do conjunto de regras fuzzy. Este *benchmark* pode, inclusive, ser utilizado para construção de outros modelos baseados em técnicas de aprendizado supervisionado.

Espera-se ainda que as abordagens dos modelos utilizem estratégias eficientes, acopladas em funções de controle SDN e NFV, que estejam em conformidade com os principais padrões de especificação em desenvolvimento (em especial as lideradas pelo 3GPP) garantindo QoS em ambiente de alto desempenho. Esses pontos constituem um campo aberto do ponto de vista de pesquisas e soluções para o mercado. Assim, a arquitetura *Network Slicing*, com um serviço bem definido e robusto de *Slice Selection*, surge como a principal solução para a próxima geração de redes móveis, possibilitando a integração e adequação em diversos segmentos e nichos de aplicações. Esta questão por si só é de extrema relevância, visto que não existe ainda padrão de indústria definido e comercializável.

O problema de seleção de *slices* para redes 5G constitui um problema ainda aberto, não dispondo de uma técnica totalmente aceita. Outras abordagens podem ser implementadas, considerando por exemplo, aspectos de mobilidade por parte do terminal móvel. É importante frisar que algumas melhorias podem ser propostas na abordagem utilizando somente lógica fuzzy, como por exemplo uma modelagem adaptativa dos parâmetros que definem cada variável linguística. Por fim, novas abordagens podem ser testadas, considerando a viabilidade da sua implantação, observando aspectos como necessidade de baixo processamento por parte do dispositivo móvel, além de menor consumo de energia.

## Referências

- [1] BALMER, R. E., LEVIN, S. L., AND SHMIDT, S. Artificial Intelligence Applications in Telecommunications and other network industries. *Telecommunications Policy* 44 (2020) 101977 (May 2020).
- [2] BISCHOFF, E. Estudo da utilização de algoritmos genéticos para seleção de redes de acesso.
- [3] CASTILLO, E. F., RENDON, O. M. C., ORDONEZ, A., AND ZAMBENEDETTI GRANVILLE, L. IPro: An approach for intelligent SDN monitoring. *Computer Networks* 170 (2020), 107108.
- [4] CHAGAS DA SILVA, D., BRESSAN, G., FIRMINO DE SOUSA, M. A., AND SILVEIRA, R. M. 5G network slice selector in IoT services scenarios with QoS requirements guarantee. In *2022 IEEE Wireless Communications and Networking Conference (WCNC) (IEEE WCNC 2022)* (Austin, USA, Apr. 2022).
- [5] HAYKIN, S. *Redes Neurais: Princípios e Prática.*, 2 ed. Bookman, 2001.
- [6] HUSAIN, S., KUNZ, A., PRASAD, A., SAMDANIS, K., AND SONG, J. *Mobile Edge Computing with Network Resource Slicing for Internet-of-Things*. IEEE World Forum - IoT (WF-IoT, 2018).
- [7] IOANNOU, I., CHRISTOPHOROU, C., VASSILIOU, V., AND PITSILLIDES, A. A novel distributed ai framework with ml for d2d communication in 5g/6g networks. *Computer Networks* 211 (2022), 108987.
- [8] IWAMURA, M. NGMN View on 5G Architecture, 2015.
- [9] KARATAS, F., AND KORPEOGLU, I. Fog-Based Data Distribution Service (F-DAD) for Internet of Things (IoT) applications. *Future Generation Computer Systems* 93 (2019), 156–169.
- [10] KUKLINSKI, S., TOMASZEWSKI, L., OSINSKI, T., KSENTINI, A., FRANGOUDIS, P. A., CAU, E., AND CORICI, M. A reference architecture for network slicing. In *2018 4th IEEE Conference on Network Softwarization and Workshops (NetSoft)* (2018), pp. 217–221.

- [11] KYMALAINEN, K. 5G System; Network Slice Selection Services; Stage 3, 3GPP TS 29.531, v1.0.0. techreport, 3GPP Organizational Partners, Mar. 2018.
- [12] LIU, Q., HAN, T., AND MOGES, E. EdgeSlice: Slicing Wireless Edge Computing Network with Decentralized Deep Reinforcement Learning.
- [13] LV, Z., CHEN, D., LOU, R., AND WANG, Q. Intelligent edge computing based on machine learning for smart city. *Future Gener. Comput. Syst.* 115 (2021), 90–99.
- [14] MESTRES, A., RODRIGUEZ-NATAL, A., CARNER, J., BARLET-ROS, P., ALARCON, E., SOLE, M., MUNTES-MULERO, V., MEYER, D., BARKAI, S., HIBBETT, M. J., ESTRADA, G., MARUF, K., CORAS, F., ERMA-GAN, V., LATAPIE, H., CASSAR, C., EVANS, J., MAINO, F., WALRAND, J., AND CABELLOS, A. Knowledge-Defined Networking. *SIGCOMM Comput. Commun. Rev.* 47, 3 (Sept. 2017).
- [15] MONTEIRO, C. D. C. *Um ambiente para apoio A integracao de Redes Sem Fio heterogeneas*. PhD thesis, Universidade de Brasília, 2012.
- [16] MORGADO, A., HUQ, K., AND MUMTAZ, S. A survey of 5G technologies: regulatory, standardization and industrial perspectives. *Digital Communications and Networks* 4 (2018), 87–97.
- [17] PHAM, Q.-V., FANG, F., HA, V. N., PIRAN, M. J., LE, M., LE, L. B., HWANG, W.-J., AND DING, Z. A Survey of Multi-Access Edge Computing in 5G and Beyond: Fundamentals, Technology Integration, and State-of-the-Art. *IEEE Access* 8 (2020), 116974–117017.
- [18] SOVERI, M. C. Management of network slicing in mobile networks; concepts, usecases and requirements, 3gpp ts 28.530, v0.5.0. techreport, Feb. 2018.
- [19] TALEB, T., AFOLABI, I., SAMDANIS, K., AND YOUSAF, F. Z. On Multi-Domain Network Slicing Orchestration Architecture and Federated Resource Control. *IEEE Network* 33 (2019), 242–252.
- [20] TALEB, T., SAMDANIS, K., MADA, B., FLINCK, H., DUTTA, S., AND SABELLA, D. On Multi-Access Edge Computing: A Survey of the Emerging 5G Network Edge Cloud Architecture and Orchestration. *IEEE Communications Surveys Tutorials* 19, 3 (2017), 1657–1681.
- [21] USAMA, M., MITRA, R. N., ILAHI, I., QADIR, J., AND MARINA, M. K. Examining machine learning for 5g and beyond through an adversarial lens.
- [22] VASILAKOS, X., NIKAEIN, N., LORENZ, D. H., KOKSAL, B., AND FERDOSIAN, N. Integrated methodology to cognitive network slice management in virtualized 5g networks.
- [23] YU, S., CHEN, X., YANG, L., WU, D., BENNIS, M., AND ZHANG, J. Intelligent Edge: Leveraging Deep Imitation Learning for Mobile Edge Computation Offloading. *IEEE Wireless Communications* 27, 1 (2020), 92–99.